

# Localización de armas de fuego en imágenes y video usando Computer Vision

## PROBLEMA

Debido al narcotráfico, el tráfico de armas de fuego al Ecuador ha incrementado. Por lo tanto, se han establecido medidas de seguridad. Sin embargo, estas medidas no han sido efectivas en frenar el crecimiento de los crímenes violentos con armas de fuego. Entonces, es necesario recurrir a otros medios para localizar elementos peligrosos. El problema que se quiere resolver en este proyecto es la falta de medidas para localizar automáticamente armas de fuego en el ambiente urbano.


## OBJETIVO GENERAL

- Localizar la presencia de un arma de fuego en un ambiente urbano para alertar en el menor tiempo posible a las autoridades.



## SOLUCIÓN

- Se utilizó un dataset de la Universidad de Granada que contiene 3000 imágenes distintas que contenían un arma de fuego, además para cada imagen había una bounding box correspondiente.
- En total el set de entrenamiento tuvo 2100 imágenes, el de validación 420 y el de test 210.
- Se utilizó una red neuronal convolucional con 2 capas con 32 filtros de 5x5, 2 capas con 64 filtros de 3x3, 2 capas con 128 filtros de 3x3 y 2 capas con 256 filtros de 3x3.
- También se usó una red MLP con 3 capas de 128, 64 y 32 neuronas; con una capa de 4 salidas con activación sigmoidal.
- Batch Normalization, Dropout de 0.3 y L2 Kernel Regularization de 0.01 para tener un modelo que se adapte mejor al problema.

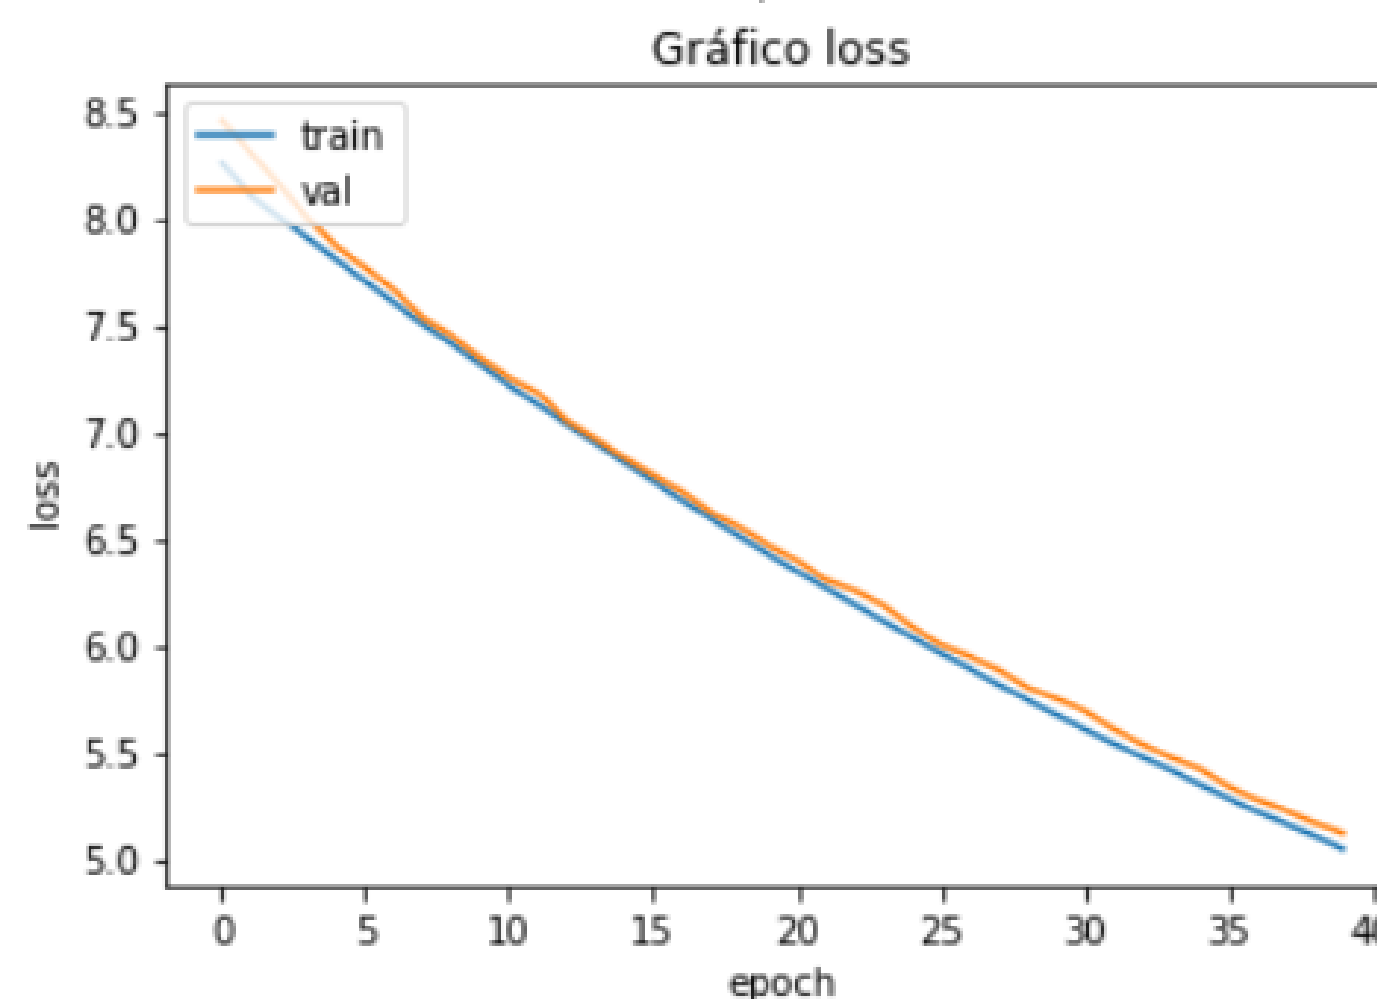
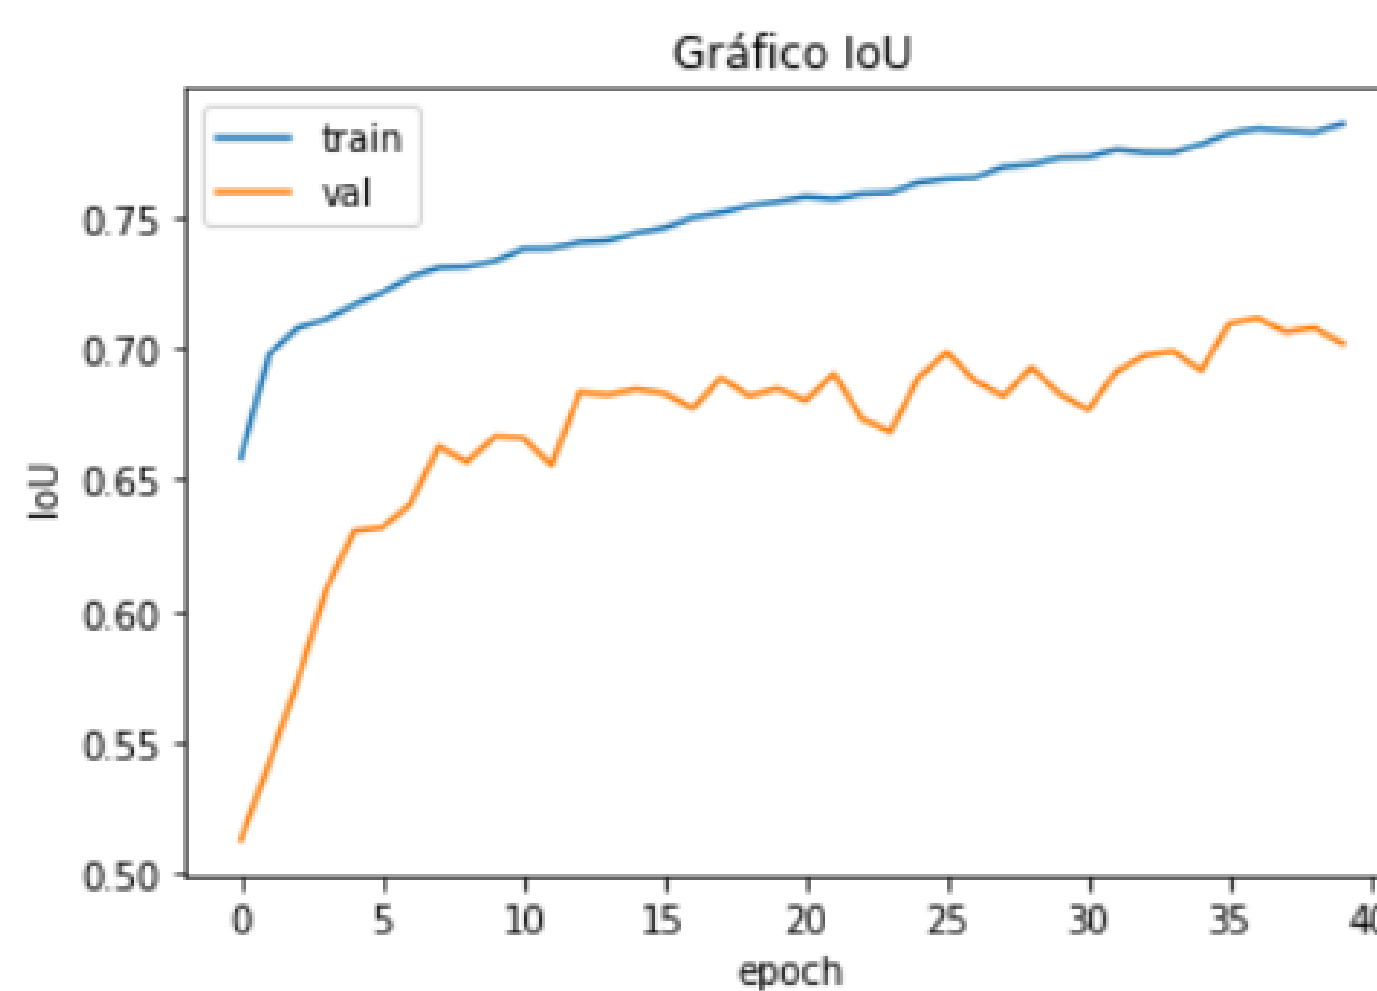


## RESULTADOS

- La métrica usada para evaluar el modelo fue IoU (Intersection Over Union) que se calcula de la siguiente manera:

$$IoU = \frac{\text{Área de Intersección}}{\text{Área de Unión}} = \frac{\text{Area of Intersection}}{\text{Area of Union}}$$

- El mejor modelo entrenado, obtuvo un 0.78 en la métrica de IoU para entrenamiento.
- En dicho modelo, para validación y test se obtuvo un IoU de 0.7 y 0.69 respectivamente.
- La pérdida se redujo de manera consistente en el entrenamiento, sin embargo, cerca del final en la muestra de validación el ritmo de reducción empeoró.
- El cambio en IoU fue más consistente en la muestra de entrenamiento vs la muestra de validación.



## CONCLUSIONES

- Hyperparámetros como el Batch Normalization, L2 Regularization y el inicializador Glorot Normal fueron útiles para evitar mínimos locales no favorables al inicio del entrenamiento.
- El modelo era muy complejo y causaba problemas en la aplicación, debido a que esta complejidad no impactaba los resultados se optó por utilizar un modelo más simple.
- Las métricas más populares para evaluar modelos CNN no eran adecuadas para evaluar la precisión de las bounding boxes, al final se utilizó Intersection Over Union.

## NUESTRA CONTRIBUCIÓN

- Modelo CNN ligero usando Batch Normalization antes de la activación ReLU, L2 Regularization y Glorot Normal Initialization.
- Implementación de métrica IoU modificada solo para bounding boxes sin considerar precisión de clasificación.